

Анализ тайм-трекинга и поиск недель, требующих ручной проверки

Курсовой проект по ИИ-майнору

Финальная версия: постановка задачи, EDA, модель, интерпретация и scoring

Выполнил: Вадим Миху

1. Бизнес-контекст

Датасет содержит необфусцированные записи тайм-трекинга из внутренней системы учета.

Цель бизнеса:

автоматически выделять пользователь-недели, которые стоит проверить вручную по истории трекинга.

Здесь важна не сумма часов сама по себе, а косвенные признаки, указывающие на нетипичный паттерн заполнения.

2. Что считается целевой задачей

Это **бинарная классификация** на уровне `user-week` :

- `0` – обычная неделя;
- `1` – неделя повышенного риска, которую стоит посмотреть вручную.

Результат модели используется как **ранжированный список на проверку**, а не как окончательный вердикт.

3. Важная оговорка по данным

Это не “чистое время работы в момент выполнения”, а **журнал внесения времени в систему**.

Из этого следует:

- `date` – дата записи, а не обязательный фактический момент работы;
- выходные сами по себе не являются ошибкой;
- крупные блоки часов могут быть нормой;
- календарные признаки используются осторожно;
- более полезны признаки структуры трекинга.

4. Гипотеза проекта

Если построить признаки, отражающие структуру трекинга, то модель сможет выделять недели с нетипичным поведением.

Ожидаемый эффект:

- быстрее находить спорные недели;
- снижать объем ручного просмотра;
- фокусировать внимание на записях с высокой концентрацией времени, слабым разнообразием задач и общим временем `mgmt/time` .

5. Исходные данные и размерность

Исходный файл после очистки:

- **12 866** записей;
- **17** столбцов.

После агрегации на уровень `user-week` :

- **1 135** недельных наблюдений;
- **29** признаков до отбора финального набора.

6. Что показал EDA

Основные выводы:

- `mgmt/time` находится в `project_path`, а не в `task`;
- календарный день сам по себе слабый сигнал;
- выходные сопоставимы с буднями по среднему объему трекинга;
- это указывает на особенности внесения времени, а не на ошибку данных;
- небольшие недели и единичные записи дают ложный высокий риск, поэтому их нужно фильтровать или штрафовать отдельно.

7. Финальные признаки

На уровне `user-week` использовались:

- `tracks` , `total_hours` , `active_days` ;
- `unique_projects` , `unique_tasks` ;
- `general_share` , `weekend_share` ;
- `top_task_share` , `top_project_share` ;
- `long_track_share` ;
- `empty_comment_share` , `avg_comment_len` ;
- нормализованные признаки: часы на запись, часы на активный день, записи на активный день.

8. Целевая переменная и proxy-target

Истинной разметки “отлынивает / не отлынивает” нет.

Поэтому был построен **proxy-target**.

Неделя считается рискованной, если сочетаются:

- высокая доля `mgmt/time` ;
- высокая концентрация времени в одной задаче или проекте;
- большое число длинных записей;
- низкое разнообразие задач;
- слабое качество комментариев.

Порог для positive class: верхние **15%** по risk-score.

9. Баланс классов

После построения proxy-target получили:

- **793** обычные недели;
- **140** недель ручной проверки.

Это означает заметный дисбаланс классов, поэтому accuracy не является основной метрикой.

10. Метрика качества

Основная метрика – **F2-score**.

Почему:

- положительный класс редкий;
- пропуск подозрительной недели дороже лишней проверки;
- F2 сильнее штрафует false negative, чем F1.

Дополнительно анализировались:

- precision;
- recall;
- ROC-AUC;
- PR-AUC.

11. Бейзлайны

Построены две простые модели:

1. **DummyClassifier**

- константное предсказание наиболее частого класса;
- дает нижнюю границу качества.

2. **Logistic Regression**

- интерпретируемый baseline для табличных данных;
- использует медианную imputation и стандартизацию.

Оба baseline нужны для сравнения с более сложной моделью.

12. Результаты бейзлайнов

На отложенной выборке:

Модель	F2	Precision	Recall	ROC-AUC	PR-AUC
DummyClassifier	0.000	0.000	0.000	0.500	0.201
Logistic Regression	0.974	0.884	1.000	0.999	0.995

Вывод: простой линейный baseline уже очень сильный, что говорит о хорошей структурированности признаков.

13. Более сложная модель

В качестве основной модели выбран **RandomForestClassifier**.

Причины выбора:

- хорошо работает на табличных признаках;
- учитывает нелинейности и взаимодействия;
- не требует масштабирования;
- удобен для интерпретации через permutation importance и SHAP.

Подбор гиперпараметров выполнялся на кросс-валидации с оптимизацией F2.

14. Подбор гиперпараметров

Лучшие параметры RandomForest:

- `n_estimators = 200`
- `max_depth = 6`
- `min_samples_split = 10`
- `min_samples_leaf = 2`
- `max_features = 0.7`

Лучший CV F2: **0.7349**

Это ниже, чем у логистической регрессии на тесте, поэтому в этой задаче сложная модель не дала выигрыша по качеству, но осталась полезной для интерпретации и проверки нелинейных эффектов.

15. Итоговые результаты модели

На тестовой выборке:

Модель	F2	Precision	Recall	ROC-AUC	PR-AUC
Logistic Regression	0.974	0.884	1.000	0.999	0.995
RandomForest tuned	0.914	0.800	0.947	0.982	0.916

Вывод: для этой задачи лучшим качеством обладает логистическая регрессия, а RandomForest показывает немного более слабый, но всё ещё качественный результат.

16. Подбор рабочего порога

Для production-скоринга порог выбирался отдельно по F2.

Лучший порог на обучающей части: **0.17**

Best CV F2 при этом пороге: **0.8198**

На тесте при этом пороге:

- F2 = **0.876**
- precision = **0.585**
- recall = **1.000**

Это хороший режим, если важнее не пропустить рискованные недели.

17. Производственный scoring

Итоговый результат – таблица `user-week` со столбцами:

- `risk_score` ;
- `risk_level` (`low` / `medium` / `high`);
- `risk_prediction` ;
- причины по SHAP;
- основные агрегаты по трекингу.

Это уже пригодно для ручного контроля и BI-отчета.

18. Примеры высокого риска

В топе risk-score оказались недели с признаками:

- концентрации времени в одной задаче;
- высокой доли общего времени;
- малым разнообразием задач;
- длинными записями.

Примеры из scoring:

- `pride13 / 2026-04-21 - risk_score = 0.990`
- `pride13 / 2026-04-28 - risk_score = 0.976`
- `juko / 2026-03-31 - risk_score = 0.964`

19. Глобальная интерпретация модели

По permutation importance сильнее всего влияют:

- top_task_share
- general_share
- long_track_share
- weekend_share
- top_project_share

Это согласуется с бизнес-логикой: модель реагирует на концентрацию времени, общий трекинг и структуру заполнения, а не на случайные шумовые признаки.

20. Локальная интерпретация

SHAP для отдельных недель показывает, почему риск вырос или снизился.

Для high-risk примера модель усиливают:

- высокая концентрация на одной задаче;
- малое число уникальных задач;
- длинные записи;
- слабое разнообразие трекинга.

Для low-risk примера риск снижается за счет:

- большего числа записей;
- большего числа задач;
- более распределенного трекинга.

21. Экспертная интерпретация

Модель ведет себя адекватно, если на первом месте оказываются:

- концентрация времени;
- доля `mgmt/time` ;
- качество и структурность комментариев;
- объем и разнообразие записей.

Это соответствует не "лени", а **нетипичной структуре ведения трекинга**, что и было целью проекта.

22. Практическое применение

Решение можно использовать как:

- приоритизацию ручной проверки;
- еженедельный список аномальных недель;
- основу для внутреннего мониторинга качества трекинга;
- триггер для дополнительной проверки спорных записей.

То есть модель не заменяет человека, а сокращает объем поиска.

23. Ограничения и дальнейшие шаги

Ограничения текущего решения:

- proxy-target не является истинной разметкой;
- часть признаков отражает стиль заполнения, а не фактическое поведение;
- поведение сотрудников может отличаться по подразделениям и ролям.

Следующие шаги:

- собрать экспертную разметку нескольких недель;
- перейти от proxy-target к supervised learning на реальной метке;
- добавить отдельные модели для разных типов команд;
- улучшить калибровку вероятностей;
- встроить scoring в еженедельный отчёт.

24. Итог

В проекте был пройден полный цикл ML-разработки:

- сформулирована бизнес-задача;
- исследованы данные;
- построены признаки;
- определены target и метрика;
- обучены baseline и ансамблевая модель;
- выполнена интерпретация;
- собран прикладной риск-скоринг.

Главный результат:

модель ранжирует недели по риску нетипичного трекинга и помогает сфокусировать ручную проверку на наиболее подозрительных случаях.